

2.8 - Serverless: o custo escondido

Cold starts, estado e lock-in de plataforma

800ms de cold start no checkout

- **Endpoint de cotação de frete migrado para Lambda**
 - Chamado a cada produto adicionado ao carrinho

LUNALOG

A LunaLog tentou usar Lambda para o endpoint de cotação de frete, aquele que o e-commerce chama toda vez que o consumidor adiciona um produto ao carrinho. O cold start da função introduzia 800ms de latência nas primeiras chamadas de cada período de inatividade. O cliente que integrou com esse endpoint sentiu a lentidão no checkout e cancelou a integração. A função era barata, mas o custo real apareceu na experiência do usuário. Esta aula existe para você não repetir o erro.

As limitações que o catálogo não anuncia

- **Cold start adiciona latência na primeira invocação**
 - Função inativa precisa ser carregada antes de responder
- **Tempo de execução tem limite rígido**
 - Processos longos não cabem no modelo FaaS
- **Estado precisa morar fora da função**
 - Nada persiste entre uma invocação e a próxima
- **Serviços proprietários criam dependência de plataforma**
 - Quanto mais específico, mais difícil sair depois

Onde serverless brilha vs. onde tropeça

Serverless brilha

- Cargas esporádicas e imprevisíveis
- Processamento assíncrono sem estado
- Automações disparadas por evento
- Latência de cold start tolerada

Serverless tropeça

- Endpoints sensíveis a latência
- Processos longos e contínuos
- Tráfego alto e constante
- Estado pesado dentro da função

Lock-in é uma decisão, não um acidente

- Cada serviço proprietário aprofunda o lock-in
- Sair depois custa mais do que parece no início

Lock-in não é necessariamente ruim, mas precisa ser uma escolha consciente. Decida quanto de portabilidade você abre mão em troca de velocidade, e registre essa decisão em um ADR.

- Abstraia o que for crítico, aceite o lock-in no resto



Serverless desacopla parte do problema, mas os serviços ainda chamam serviços diretamente. Existe um estilo que vai além: em vez de um componente pedir algo a outro, ele apenas anuncia que um fato aconteceu, e quem se interessa reage. O modelo mental muda por completo. E se ninguém precisasse saber quem está ouvindo?

Arquitetura orientada a eventos