

3.1 - Escalabilidade horizontal e vertical

Onde o sistema cresce, e onde ele trava

Três dias antes da Black Friday

- **Pico crescente de requisições das transportadoras**
 - Resposta rápida e tentadora: aumentar o servidor existente

LUNALOG

É novembro de 2022, três dias antes da Black Friday, e o dashboard da LunaLog mostra o tráfego subindo hora a hora. Roberto vai pelo caminho óbvio, aumentar a máquina, mais CPU, mais memória. Ana o interrompe com uma pergunta simples: o serviço de tracking está pronto para rodar em mais de uma instância? A resposta é não, ele guarda sessão na memória local. Naquele instante ficou claro que escalar para os lados exige uma decisão de design tomada muito antes de o pico chegar.

Vertical e horizontal: dois caminhos

Crescer para cima ou crescer para os lados

- **Escala vertical aumenta recursos de uma única máquina**
 - Mais CPU, mais memória, mais disco no mesmo nó
- **Escala horizontal adiciona mais instâncias em paralelo**
 - Trabalho distribuído entre vários nós atrás de um balanceador
- **Vertical tem teto físico e custo que cresce rápido**
 - Máquinas grandes ficam caras e o hardware tem limite
- **Horizontal tem teto bem mais alto, com outra complexidade**
 - Exige coordenação, rede e estado externalizado

Quando cada abordagem faz sentido

Escala vertical (scale-up)

- Implementação simples, sem mudar a aplicação
- Boa para cargas que cabem em uma máquina
- Limite físico de CPU, memória e disco
- Ponto único de falha permanece
- Custo cresce de forma não linear

Escala horizontal (scale-out)

- Exige aplicação stateless para funcionar
- Cresce de forma quase linear com a carga
- Tolerância a falha de instâncias individuais
- Habilita elasticidade automática na cloud
- Adiciona complexidade de rede e coordenação

Statelessness é pré-requisito, não detalhe

- **Instância sem estado local pode ser substituída a qualquer momento**
- **Sessão e estado vão para cache ou banco compartilhado**

Sem statelessness, adicionar instâncias não distribui carga, apenas multiplica o problema. Elasticidade cloud-native depende dessa decisão de design tomada cedo.

- Elasticidade é escalar para cima e para baixo conforme a demanda



Escala horizontal ou vertical parece uma decisão puramente técnica. Mas existe uma força que molda a arquitetura muito antes de qualquer diagrama: a forma como as próprias equipes se comunicam. E quando você ignora essa força, o sistema te lembra dela do jeito mais doloroso.

Lei de Conway: a organização vira arquitetura