

3.4 - Caching distribuído

Responder rápido sem ir ao banco toda vez

Os quatro padrões de cache

Quem lê, quem escreve e em que ordem

- **Cache-aside: a aplicação consulta o cache antes do banco**
 - Em miss, busca no banco e popula o cache
- **Read-through: o cache busca no banco por você**
 - A aplicação fala só com o cache, que cuida do resto
- **Write-through grava no cache e no banco juntos**
 - Consistência alta ao custo de latência de escrita
- **Write-behind grava no cache e persiste depois**
 - Escrita rápida, com risco de perda em falha

Padrões de leitura e de escrita

Foco em leitura

- Cache-aside dá controle total à aplicação
- Read-through esconde o banco do código
- TTL define por quanto tempo o dado vale
- Ideal para dados lidos muito mais que escritos

Foco em escrita

- Write-through prioriza consistência imediata
- Write-behind prioriza latência de escrita
- Invalidação mantém cache e banco alinhados
- Exige estratégia clara contra dado obsoleto

Quando o cache expira ao mesmo tempo

- **Cache stampede** ocorre quando muitas chaves expiram juntas
- **Thundering herd**: milhares de misses atingem o banco de uma vez

Um cache mal calibrado não só deixa de ajudar, ele cria um pico de carga sincronizado no banco. Use TTL com jitter e lock de regeneração para evitar a estampida.

De 450ms para 12ms

- **Consulta de tarifas chamada quatrocentas vezes por segundo**
 - Noventa por cento das consultas repetem as mesmas rotas

LUNALOG

No pico de checkout, o serviço de tarifas de frete da LunaLog era chamado quatrocentas vezes por segundo, e uma análise revelou que noventa por cento das consultas eram para rotas repetidas. O time implementou cache-aside com TTL de cinco minutos. A carga no banco caiu oitenta e cinco por cento e a latência média despencou de quatrocentos e cinquenta milissegundos para doze. A maior melhoria de performance do ano não veio de hardware mais caro, veio de um cache bem projetado.



Cache resolve o problema da leitura repetida com elegância. Mas quando o pico inverte, dez mil escritas chegando ao mesmo tempo, o cache não ajuda em nada e o banco trava de qualquer forma. Existe uma válvula de pressão feita para escrita, e ela muda a forma como o sistema absorve picos.

Filas de mensagens e processamento assíncrono