

3.5 - Filas e processamento assíncrono

A válvula de pressão dos picos de escrita

O papel das filas de mensagens

Desacoplar quem produz de quem consome

- **Desacoplamento temporal entre producer e consumer**
 - O produtor não espera o consumidor terminar
- **Suavização de picos com buffer entre as pontas**
 - A fila absorve a rajada e libera no ritmo possível
- **Reprocessamento natural em caso de falha**
 - Mensagem volta para a fila e é tentada de novo
- **Producer e consumer escalam de forma independente**
 - Mais consumidores aumentam a vazão sem tocar no produtor

Dez mil confirmações ao mesmo tempo

- **Confirmações de entrega gravadas de forma síncrona**
 - Pico no fim da tarde leva o banco ao limite

LUNALOG

Na LunaLog, cada confirmação de entrega gravava direto no banco, de forma síncrona. Numa tarde de pico, dez mil motoristas confirmaram entregas quase ao mesmo tempo, o banco travou e o sistema passou a rejeitar requisições inteiras. O time colocou uma fila entre o endpoint de confirmação e o processador. A partir dali, a confirmação era aceita na hora e processada no ritmo que o banco suportava. Nada de dado perdido, nada de requisição rejeitada, só a rajada virando um fluxo controlado.

Síncrono ou assíncrono

O critério que define o que vai para a fila

- **Síncrono quando o cliente precisa do resultado agora**
 - Login, pagamento, validação que bloqueia o próximo passo
- **Assíncrono quando o trabalho pode esperar um instante**
 - Notificações, relatórios, processamento em lote
- **At-least-once entrega a mensagem ao menos uma vez**
 - Exige consumidor idempotente para tolerar duplicatas
- **Exactly-once é caro e raramente necessário**

Nem tudo deve ser assíncrono

- Fila adiciona latência, monitoramento e ordem eventual
- Async indevido transforma erro simples em falha invisível

A pergunta não é se a fila é poderosa, é se a operação tolera não ter resposta imediata. Quando o usuário precisa de confirmação na hora, fila é complexidade sem retorno.



Agora o sistema absorve picos de escrita sem suar. Mas existe uma fronteira que ainda não tocamos: como esse sistema se apresenta para o mundo lá fora. Um contrato de API mal desenhado escala o problema junto com o tráfego, e cada novo cliente integrado torna o conserto mais caro.

Design de APIs REST para escala